

The Llama 3 Herd of Models

introdudction

Large Language Models 비쌈

- GPT-3: 너무 큼 (175B parameters)
- 학습 비용 매우 큼
- 연구자들이 재현하기 어려움

기존 연구

- 모델의 크기를 계속 증가 시킴 -> 성능 높이는 방식
- 비효율적
- 비용이 매우 큼

LlaMA Approach

- 데이터 품질과 학습 방식에 집중
- 더 많은 토큰
- 효율적인 스케일링 전략 사용

		Llama 3 8B			Llama 3 70B			Llama 3 405B			Claude 3.5 Sonnet	
Category	Benchmark	Llama 3 8B	Gemma 2 9B	Mistral 7B	Llama 3 70B	Mixtral 8x22B	GPT 3.5 Turbo	Llama 3 405B	Nemotron 4 340B	GPT-4o (2025)	GPT-4o	Claude 3.5 Sonnet
General	MMLU (5-shot)	69.4	72.3	61.1	83.6	76.9	70.7	87.3	82.6	85.1	89.1	89.9
	MMLU (0-shot, CoT)	73.0	72.3 [△]	60.5	86.0	79.9	69.8	88.6	78.7 [◇]	85.4	88.7	88.3
	MMLU-Pro (5-shot, CoT)	48.3	—	36.9	66.4	56.3	49.2	73.3	62.7	64.8	74.0	77.0
	IFEval	80.4	73.6	57.6	87.5	72.7	69.9	88.6	85.1	84.3	85.6	88.0
Code	HumanEval (0-shot)	72.6	54.3	40.2	80.5	75.6	68.0	89.0	73.2	86.6	90.2	92.0
	MBPP EvalPlus (0-shot)	72.8	71.7	49.5	86.0	78.6	82.0	88.6	72.8	83.6	87.8	90.5
Math	GSM8K (8-shot, CoT)	84.5	76.7	53.2	95.1	88.2	81.6	96.8	92.3 [◇]	94.2	96.1	96.4 [◇]
	MATH (0-shot, CoT)	51.9	44.3	13.0	68.0	54.1	43.1	73.8	41.1	64.5	76.6	71.1
Reasoning	ARC Challenge (0-shot)	83.4	87.6	74.2	94.8	88.7	83.7	96.9	94.6	96.4	96.7	96.7
	GPQA (0-shot, CoT)	32.8	—	28.8	46.7	33.3	30.8	51.1	—	41.4	53.6	59.4
Tool use	BFCL	76.1	—	60.4	84.8	—	85.9	88.5	86.5	88.3	80.5	90.2
	Nexus	38.5	30.0	24.7	56.7	48.5	37.2	58.7	—	50.3	56.1	45.7
Long context	ZeroSCROLLS/QuALITY	81.0	—	—	90.5	—	—	95.2	—	95.2	90.5	90.5
	InfiniteBench/En.MC	65.1	—	—	78.2	—	—	83.4	—	72.1	82.5	—
	NIH/Multi-needle	98.8	—	—	97.5	—	—	98.1	—	100.0	100.0	90.8
Multilingual	MGSM (0-shot, CoT)	68.9	53.2	29.9	86.9	71.1	51.4	91.6	—	85.9	90.5	91.6

introdudction

LLaMA 는 **고품질 기초 모델 개발** 위한 3가지 주요 요인 강조!

1. **데이터**: 약 15조(15T)개의 다국어 토큰으로 사전훈련(Llama 2 = 약 1.8T 토큰보다 훨씬 큰 규모)
-> 데이터 양과 품질 개선
2. **규모(compute)**: 3.8×10^{25} FLOPs 를 사용해 사전 훈련 (Llama 2 대비 약 50배)
-> 대표 모델 활용해 더 작은 모델들의 성능도 향상 (사후훈련)
3. **복잡성 관리**: 복잡한 구조 대신 Dense Transformer 유지, 사후훈련 때 복잡도가 높은 강화학습 기법은 채택 X
-> 모델 훈련 안정성과 확장성 증가

→즉, 성능 = Data + Compute + Training

Abstract

Llama 3

- 다중 언어 지원, 코딩, 추론 및 도구 사용을 지원하는 언어 모델의 군집
- 405B 파라미터를 가진 Dense Transformer 구조
- 최대 128K 컨텍스트 처리 가능
- 다양한 과제에서 GPT-4 수준의 성능에 근접
- 사전 훈련 및 추가 훈련 버전 모두 공개 (+ Llama Guard 3)

이미지 인식, 비디오 인식, 음성 이해 기능을 가능하게 하는 다중 모델 확장을 개발 -> 개발 중 -> 아직 공개 준비되지 않음

모델 군집 개요 (Llama 3.1 모델에 대한 것)

	Finetuned	Multilingual	Long context	Tool use	Release
Llama 3 8B	✗	✗ ¹	✗	✗	April 2024
Llama 3 8B Instruct	✓	✗	✗	✗	April 2024
Llama 3 70B	✗	✗ ¹	✗	✗	April 2024
Llama 3 70B Instruct	✓	✗	✗	✗	April 2024
Llama 3.1 8B	✗	✓	✓	✗	July 2024
Llama 3.1 8B Instruct	✓	✓	✓	✓	July 2024
Llama 3.1 70B	✗	✓	✓	✗	July 2024
Llama 3.1 70B Instruct	✓	✓	✓	✓	July 2024
Llama 3.1 405B	✗	✓	✓	✗	July 2024
Llama 3.1 405B Instruct	✓	✓	✓	✓	July 2024

LLaMA training pipeline


1. Pre-training – 지식 학습

- Next token prediction
- 15T tokens / large scale
- **Learns language & knowledge**
(대규모 데이터로 언어 지식 학습)

2. Post-training - 행동 정렬

- Supervised Fine-Tuning (SFT) – 사람이 만든 정답으로 학습
- Direct Preference Optimization (DPO) – 사람 선호 기반 최적화
- Tool use / reasoning improvement – 실제 활용 능력 강화

→ Pre-training learns knowledge,
Post-training aligns behavior



Pre-training Overview

(1) 데이터 구성

- 약 15조 개 토큰 사용
- 중복 제거 및 데이터 정제 과정 -> 고품질 토큰만 남김

(2) 스케일링 전략

- 모델 크기와 데이터 양의 균형
- 약 400B 규모 모델 학습

(3) 모델 구조

- Dense Transformer 유지
- 컨텍스트 길이 128K 확장

* 성능은 데이터와 스케일링 전략에서 결정됨

Data Curation (데이터 품질 관리)

- 개인정보(PII) 및 유해 콘텐츠 제거
: 안전하지 않은 웹사이트 및 성인 콘텐츠 필터링
- HTML 정제 및 텍스트 추출
: 웹페이지 구조를 분석하여 의미 있는 텍스트만 추출 / 다양한 정리 구성 실험을 수행한 결과 -> 웹 데이터를 주로 훈련하는 모델에서는 **마크다운이 성능에 해롭다는 것을 발견하여 모든 마크다운 마커를 제거함**
- 중복 제거 (URL / 문서 / 문장 단위)
: URL / 문서 / 문장 수준에서 반복 데이터 제거
- 휴리스틱 필터링
: 반복 문장, 이상 데이터, 추가적인 저품질 문서 제거 / **훈련 코퍼스 분포와 비교하여 과도한 수의 이상치 토큰을 포함한 문서를 필터링하기 위해 토큰 분포 Kullback-Leibler 다이버전스를 사용**
- 모델 기반 품질 필터링
: 학습된 분류기를 통해 고품질 데이터 선별 -> 다양한 품질 필터링 구성의 효능을 실험적으로 평가

즉, 단순히 많은 데이터가 아니라 **“정제된 데이터”**가 핵심

Data Strategy(데이터 전략)

- 데이터 구성 (Data Mix) - #데이터를 단순히 모으는게 아닌 비율도 중요
- : 데이터 비율 실험적으로 결정 - 지식 분류
- : 과대표 데이터 다운샘플링 - 스케일링 법칙
- : 데이터 믹스 요약 - 일반(50%) / 수학(25%) / 코드 (17%) / 다국어 균형 유지 (8%)

데이터 비율 자체도 성능에 큰 영향

- 데이터 최적화 (Annealing)

: 고품질 데이터 비중 증가

: 수학 / 코드 데이터 강화

: 성능 향상 확인

➔ GSM8K +24%

➔ MATH +6.4%

특정 도메인 데이터로 추가 성능 개선

새로운 데이터 소스를 평가하기 위해 어닐링을 사용하는 것은 모든 소규모 데이터셋에 대해 스케일링 법칙 실험을 수행하는 것보다 더 효율적

Scaling Law(스케일링 법칙)

- 컴퓨팅 자원에 따라 최적 데이터 양 존재
- 모델 성능 -> 모델 크기 + 데이터 양의 균형에 의해 결정
- 스케일링 법칙 -> 최적 학습 토큰 수 예측

$$N^*(C) = AC^\alpha.$$

- 중요한 관찰

: 컴퓨팅 예산이 증가함에 따라 IsoFLOPs 곡선이 최솟값 주위에서 평평해짐.

: 주력 모델의 성능이 모델 크기와 훈련 토큰 간의 무역 오프에 대한 작은 변화에 대해 상대적으로 강건하다는 의미.

-> 405B 매개변수를 가진 주력 모델 훈련 결정




Figure 2 Scaling law IsoFLOPs curves between 6×10^{18} and 10^{22} FLOPs. The loss is the negative log-likelihood on a held-out validation set. We approximate measurements at each compute scale using a second degree polynomial.




Figure 3 Number of training tokens in identified compute-optimal models as a function of pre-training compute budget. We include the fitted scaling-law prediction as well. The compute-optimal models correspond to the parabola minimums in Figure 2.

Training Recipe(훈련레시피)

- LLaMA3 학습은 3단계로 구성

1. 초기 사전 훈련

➔ 기본 언어 능력 학습

2. 긴 컨텍스트 사전 훈련

➔ 8K -> 최대 128K 토큰 처리

3. 어닐링 (Annealing)

➔ 학습 안정화 및 최종 성능 향상

#어닐링 - 학습률을 점진적으로 줄여서 모델이 안정적으로 수렴하도록 과정

- 훈련 단계별 전략

(1) 초기 사전 훈련

- 대규모 데이터로 기본 학습
- 학습률 점진적 감소
- 배치 크기 점진적 증가

(2) 긴 컨텍스트 학습

- 8K -> 128K로 점진적 확장
- 긴 문장 처리 능력 확보

(3) 어닐링

- 학습률 0으로 감소
- 고품질 데이터 비용 증가
- 모델 안정적 수렴

Model Architecture(모델아키텍처)

- 기본 구조: Transformer (기존과 동일)
- 큰 구조 변화 없음 -> LLaMA2와 유사
- 주요 변경 사항

GQA (Grouped Query Attention) -> 추론 속도 향상, 디코딩 중 key-value 캐시의 크기를 줄임

Attention Mask 개선(동일한 시퀀스 내의 다른 문서 간의 자기 주의를 방지하는) -> 긴 컨텍스트 학습에 유리

- 컨텍스트 길이 확장 -> 최대 128K 토큰

	8B	70B	405B
Layers	32	80	126
Model Dimension	4,096	8192	16,384
FFN Dimension	14,336	28,672	53,248
Attention Heads	32	64	128
Key/Value Heads	8	8	8
Peak Learning Rate	3×10^{-4}	1.5×10^{-4}	8×10^{-5}
Activation Function	SwiGLU		
Vocabulary Size	128,000		
Positional Embeddings	RoPE ($\theta = 500,000$)		


대규모 학습 인프라

- 최대 16K H100 GPU 사용
- 대규모 분산 학습 클러스터
→ Meta production cluster

- 스토리지 시스템
→ 240PB 데이터 처리
→ 빠른 checkpoint 지원

- 고속 네트워크 (400Gbps)

* 단순 모델이 아니라, 시스템 전체 설계가 중요!



GPUs	TP	CP	PP	DP	Seq. Len.	Batch size/DP	Tokens/Batch	TFLOPs/GPU	BF16 MFU
8,192	8	1	16	64	8,192	32	16M	430	43%
16,384	8	1	16	128	8,192	16	16M	400	41%
16,384	8	16	16	8	131,072	16	16M	380	38%

Table 4 Scaling configurations and MFU for each stage of Llama 3 405B pre-training. See text and Figure 5 for descriptions of each type of parallelism.

모델 확장을 위한 병렬화

- 단순 병렬화가 아니라 4가지 병렬화 방식을 동시에 사용하는 **4D 병렬화 구조** 사용
(모델 + 데이터 + 시퀀스 동시에 나눠서 학습)

1. Tensor Parallel (TP)

➔ 모델 내부 분할

2. Pipeline Parallel (PP)

➔ 레이어 단위 분할

3. Context Parallel (CP)

➔ 긴 입력 시퀀스 분할

4. Data Parallel (DP/FSDP)

➔ 데이터 분산 학습




Figure 5 Illustration of 4D parallelism. GPUs are divided into parallelism groups in the order of [TP, CP, PP, DP], where DP stands for FSDP. In this example, 16 GPUs are configured with a group size of $|TP|=2$, $|CP|=2$, $|PP|=2$, and $|DP|=2$. A GPU's position in 4D parallelism is represented as a vector, $[D_1, D_2, D_3, D_4]$, where D_i is the index on the i -th parallelism dimension. In this example, GPU0[TP0, CP0, PP0, DP0] and GPU1[TP1, CP0, PP0, DP0] are in the same TP group, GPU0 and GPU2 are in the same CP group, GPU0 and GPU4 are in the same PP group, and GPU0 and GPU8 are in the same DP group.

학습 효율 최적화

- GPU 활용률 : 약 38% ~ 43%

개선 방법

- 로드 밸런싱 개선


➔ 네트워크 병목 감소

- 혼잡 제어

➔ 안정적인 학습 유지

- 메모리 및 계산 최적화

➔ 병렬화 효율 증가



Component	Category	Interruption Count	% of Interruptions
Faulty GPU	GPU	148	30.1%
GPU HBM3 Memory	GPU	72	17.2%
Software Bug	Dependency	54	12.9%
Network Switch/Cable	Network	35	8.4%
Host Maintenance	Unplanned Maintenance	32	7.6%
GPU SRAM Memory	GPU	19	4.5%
GPU System Processor	GPU	17	4.1%
NIC	Host	7	1.7%
NCCL Watchdog Timeouts	Unknown	7	1.7%
Silent Data Corruption	GPU	6	1.4%
GPU Thermal Interface + Sensor	GPU	6	1.4%
SSD	Host	3	0.7%
Power Supply	Host	3	0.7%
Server Chassis	Host	2	0.5%
IO Expansion Board	Host	2	0.5%
Dependency	Dependency	2	0.5%
CPU	Host	2	0.5%
System Memory	Host	2	0.5%

Table 5 Root-cause categorization of unexpected interruptions during a 54-day period of Llama 3 405B pre-training. About 78% of unexpected interruptions were attributed to confirmed or suspected hardware issues.